

Sistema de Triage de Consultas con IA

Documentación técnica de arquitectura

Entrega final — Curso de Automatización con IA

Autor: Guido Sánchez

Agosto de 2026

Resumen del caso de uso

El sistema automatiza el triage de consultas que las empresas envían por correo a la Secretaría de Industria y Comercio. Un correo con una consulta en texto libre —sobre un régimen de promoción, un reglamento técnico, un arancel o un trámite— es leído por un modelo de lenguaje que lo clasifica por tema, urgencia y área responsable, lo contrasta contra una base de conocimiento interna y redacta un borrador de respuesta.


El borrador nunca se envía automáticamente. Queda registrado en Notion en estado «Procesado por IA» y se notifica por Slack. Solo cuando un agente humano cambia el estado a «Aprobado por Humano», el sistema envía la respuesta al remitente.

Aclaración: la totalidad de los datos utilizados —regímenes, reglamentos, empresas, correos y normativa citada— son ficticios y fueron generados específicamente para este trabajo. Ninguna consulta real de la Secretaría ingresa al sistema.

Stack tecnológico

Categoría	Herramienta	Rol en el sistema
Orquestador	n8n (autoalojado)	Flujo principal, dos ramas
Base de datos	Notion	Memoria: registro y base de conocimiento
Procesamiento IA	Cohere (Command, vía Basic LLM Chain)	Clasificación y redacción
Canal de entrada	Gmail	Disparador de consultas entrantes
Canal de salida	Slack y Gmail	Notificación HITL y respuesta final
Dashboard	Notion (vista publicada)	KPI y tasa de errores

1. Mapa de arquitectura



El sistema está compuesto por un único workflow de n8n con dos ramas que no están conectadas entre sí. Ambas se comunican exclusivamente a través de la base de datos de Notion, que actúa como estado compartido y persistente.

Rama 1 — Ingesta y procesamiento

#	Nodo	Tipo	Función
1	Trigger - Consulta entrante	Gmail Trigger	Detecta correo nuevo. Filtrado por remitente. Sondeo cada minuto.
2	Normaliza datos del mail	Set	Extrae asunto, remitente y cuerpo. Descarta los encabezados SMTP.
3	Lee base de conocimiento	Notion (Get Many)	Recupera las fichas de regímenes y reglamentos.

#	Nodo	Tipo	Función
4	Vuelve a un solo item	Limit	Evita que el modelo se ejecute una vez por ficha.
5	Clasifica y redacta borrador	Basic LLM Chain	Clasifica y redacta. Salida en JSON estructurado.
5a	Cohere Chat Model	Subnodo de modelo	Modelo de lenguaje. Máximo de reintentos: 3.
5b	Structured Output Parser	Subnodo de parseo	Fuerza el formato JSON de salida.
6	Guarda consulta en Notion	Notion (Create)	Crea el registro en estado «Procesado por IA».
7	Avisa revision por Slack	Slack	Notifica con semáforo y enlace directo a Notion.
8	Registra error en Notion	Notion (Create)	Ruta de error. Recibe las salidas de fallo de los nodos 5 y 6.

Rama 2 — Aprobación y envío

#	Nodo	Tipo	Función
9	Trigger - Cambio de estado	Notion Trigger	Detecta páginas modificadas. Sondeo cada minuto.
10	Lee la consulta completa	Notion (Get)	Recupera todos los campos de la fila.
11	Filtra aprobadas sin responder	If	Doble condición. Filtro contra bucles.
12	Envía respuesta a la empresa	Gmail	Acción crítica. Envía el borrador aprobado.
13	Marca finalizado en Notion	Notion (Update)	Estado «Finalizado» y marca la respuesta como enviada.

Por qué el flujo está partido en dos ramas

no mantiene estado entre ejecuciones. Un flujo no puede quedarse esperando a que una persona apruebe algo al día siguiente. La solución es cortarlo en dos: la rama 1 procesa y persiste el resultado en Notion; la rama 2 se dispara de forma independiente cuando el estado cambia. Notion es, precisamente, lo que hace posible el punto de validación humana.

2. Estructuras de datos

La base de datos cumple dos roles simultáneos. Como registro, guarda cada consulta procesada y hace posible tanto la validación humana como el cálculo de indicadores. Como conocimiento, provee a la IA la información controlada sobre la que debe redactar, lo que evita que invente normativa.

2.1 Tabla CONSULTAS (registro)

Una fila por consulta ingresada. Es la tabla sobre la que se calcula el dashboard.

Campo	Tipo en Notion	Valores	Quién escribe
Asunto	Title	Texto libre	Flujo (rama 1)
Remitente	Email	Dirección del solicitante	Flujo (rama 1)
Fecha ingreso	Created time	Automático	Notion
Consulta original	Rich text	Cuerpo del correo	Flujo (rama 1)
Tema	Select	Regimen de promocion / Aranceles / Reglamentos tecnicos / Tramites	IA
Urgencia	Select	Alta / Media / Baja	IA
Area responsable	Select	Cuatro direcciones (véase 2.2)	IA
Codigo ficha	Rich text	REG-001, ARA-002, etc.	IA
Tipo de resolucion	Select	Responde IA / Requiere humano / Solicita aclaracion	IA
Borrador respuesta	Rich text	Texto de la respuesta	IA
Estado	Status	Pendiente / Procesado por IA / Aprobado por Humano / Finalizado / Error	Flujo y humano
Resultado	Select	OK / Error	Flujo
Respuesta enviada	Checkbox	true / false	Flujo (rama 2)
Detalle error	Rich text	Mensaje del nodo que falló	Ruta de error
Ficha KB	Relation	Vínculo con Base de conocimiento	Humano

Nota: los nombres de campo y los valores de los desplegables se escriben sin acentos ni caracteres especiales. Es una decisión deliberada, explicada al final de este apartado.

Decisiones de diseño relevantes:

- Estado frente a Resultado: el primero refleja el ciclo de vida y cambia con el tiempo; el segundo se escribe una sola vez y no se modifica. Si la tasa de errores se calculara sobre el Estado, cada consulta corregida a mano borraría su propio error del histórico y el indicador quedaría subestimado.
- Respuesta enviada: garantiza la idempotencia. Si el envío del correo tiene éxito pero la escritura posterior en Notion falla, sin este campo el disparador volvería a activarse y el destinatario recibiría el mismo correo repetidamente.
- Agrupación del campo Estado: «Pendiente» en To-do; «Procesado por IA» y «Aprobado por Humano» en In progress; «Finalizado» y «Error» en Complete.

2.2 Tabla BASE DE CONOCIMIENTO

Se carga manualmente. El flujo solo la lee y nunca escribe en ella, por lo que no puede originar bucles.

Campo	Tipo en Notion	Función
Nombre	Title	Denominación del régimen o reglamento
Codigo	Rich text	Identificador: REG-001, ARA-001, RTE-001
Tipo	Select	Mismo vocabulario que el campo Tema de Consultas
Area responsable	Select	Dirección a cargo

Campo	Tipo en Notion	Función
Resumen	Rich text	Descripción que la IA utiliza para redactar
Requisitos	Rich text	Lista de requisitos aplicables
Requiere revision humana	Checkbox	Fuerza la derivación aunque exista información disponible
Consultas relacionadas	Relation	Propiedad espejo de Ficha KB

El campo «Requiere revisión humana» traslada una regla de negocio desde el prompt hacia la base de datos. Que un tema deje de responderse de forma automática no requiere modificar el workflow: basta con tildar la casilla en Notion.

Vocabularios controlados (idénticos en ambas tablas):

Tema / Tipo	Área responsable
Regimen de promocion	Direccion nacional de inversiones y desarrollo industrial
Aranceles	Direccion nacional de politica comercial externa
Reglamentos tecnicos	Direccion nacional de reglamentos tecnicos y promocion de la calidad
Tramites	Coordinacion de gestion documental y despacho

Sobre la ausencia de acentos en los nombres de campo y en los valores: n8n compara cadenas de texto de forma exacta y sensible a mayúsculas. Una diferencia de un solo carácter entre lo que escribe Notion y lo que espera un filtro provoca que la rama no se ejecute, sin generar ningún error visible. Normalizar los identificadores elimina toda una categoría de fallos silenciosos. Los textos de contenido —resúmenes, requisitos y borradores— sí conservan la ortografía completa, porque nunca se comparan.

2.3 Esquemas JSON de transferencia

Salida del nodo «Normaliza datos del mail». El correo entrante ronda los 7.700 caracteres incluidos los encabezados SMTP, las firmas DKIM y la versión HTML; la normalización lo reduce a tres campos.

```
{
  "asunto": "Consulta sobre requisitos del RMLP",
  "remitente": "empresa@ejemplo.com",
  "cuerpo": "Buenos días. Somos Metalurgica Sur SRL..."
}
```

Salida del nodo «Clasifica y redacta borrador». El formato se fuerza mediante un Structured Output Parser.

```
{
  "output": {
    "tema": "Regimen de promocion",
    "urgencia": "Media",
    "area_responsable": "Direccion nacional de inversiones...",
    "codigo_ficha": "REG-001",
    "tipo_resolucion": "Responde IA",
    "borrador": "Estimado Juan Perez, ..."
  }
}
```

Lectura de la base de conocimiento (Notion, modo simplificado). Un objeto por ficha:

```
{
  "id": "3bfa0733-e0ae-8030-a870-da7266de6a67",
  "property_codigo": "REG-001",
  "property_nombre": "Regimen de Modernizacion de Lineas Productivas",
  "property_tipo": "Regimen de promocion",
  "property_area_responsable": "Direccion nacional de inversiones...",
  "property_resumen": "Permite importar con arancel del 0%...",
  "property_requisitos": "Proyecto de inversion aprobado / ...",
  "property_requiere_revision_humana": false
}
```

Nota sobre el mapeo de campos: el Notion Trigger y el nodo Notion (Get) devuelven los nombres de propiedad en formatos distintos. El disparador los entrega tal como figuran en Notion («Estado»), mientras que el nodo Get los normaliza a minúsculas con prefijo («property_estado»). Referenciar el formato equivocado devuelve un valor indefinido sin generar error, y la condición que lo utilice nunca se cumple. Por ese motivo la rama 2 lee la fila completa con un nodo Get antes de evaluar el filtro, en lugar de operar sobre la salida directa del disparador.

3. Optimización de costos

3.1 Consumo medido por consulta

Estimación sobre las corridas de prueba realizadas:

Componente	Volumen aproximado	Observación
Instrucciones del prompt	~600 tokens	Fijo por ejecución
Base de conocimiento (7 fichas)	~850 tokens	Crece de forma lineal con la cantidad de fichas
Consulta normalizada	~300 tokens	Techo de 4.000 caracteres por truncado
Total de entrada	~1.750 tokens	
Salida (JSON y borrador)	~400 tokens	Acotada por instrucción de longitud
Llamadas al modelo	1 por consulta	El nodo Limit evita la multiplicación por ficha

3.2 Matriz comparativa de modelos

Costo estimado para 1.000 consultas mensuales (1,75 millones de tokens de entrada y 0,4 millones de salida). Los precios son de lista, a título de referencia, y deben verificarse contra el tarifario vigente de cada proveedor al momento de implementar.

Modelo	Entrada USD/1M	Salida USD/1M	Costo 1.000 consultas	Adecuación a la tarea
Cohere Command (plan gratuito)	0	0	USD 0	ELEGIDO. Suficiente para clasificar sobre un vocabulario cerrado y redactar textos breves con contexto acotado. El límite de tasa resulta aceptable para el volumen previsto.
GPT-4o-mini	~0,15	~0,60	~USD 0,50	Alternativa equivalente. Sería la opción si se requiriera un acuerdo de nivel de servicio productivo.
Claude Haiku	~0,80	~4,00	~USD 3,00	Mejor calidad de redacción en castellano formal. Justificable si el borrador se enviara sin revisión previa.
GPT-4o o Claude Sonnet	~2,50	~10,00	~USD 8,50	DESCARTADO. La tarea no requiere razonamiento complejo: el contexto es corto, el vocabulario es cerrado y la salida es un formulario JSON.

3.3 Criterio de asignación por tarea

Tarea	Complejidad	Modelo indicado
Clasificación (tema, urgencia, área)	Baja: elección sobre vocabulario cerrado	Modelo económico (Cohere o GPT-4o-mini)
Selección de ficha	Baja o media: correspondencia semántica sobre siete registros	Modelo económico
Redacción del borrador	Media: castellano formal, sin invención	Modelo económico con revisión humana
Lectura de normativa extensa	Alta: no aplica en este sistema	Modelo de contexto largo (Claude)
Procesamiento masivo histórico	No aplica: el flujo es por evento	API de lotes (Batch), 50 % de descuento

3.4 Medidas de control implementadas

Medida	Implementación	Efecto
Truncado de entrada	slice(0, 4000) en el nodo Set	Techo estricto por consulta; evita que una cadena larga de respuestas citadas dispare el consumo
Normalización previa	Descarte de encabezados SMTP y HTML	Reducción de unos 7.700 a unos 300 caracteres
Una llamada por consulta	Nodo Limit	Evita siete llamadas por correo, una por ficha: reducción del 86 %
Salida acotada	Instrucción de longitud en el prompt	Limita los tokens de salida
Disparador filtrado	Filtro por remitente en el Gmail Trigger	Solo se procesa correo de la casilla habilitada
Sin reintentos ciegos	Máximo de tres reintentos con espera	Evita bucles de reintento indefinidos

Nota: la versión del nodo Cohere Chat Model utilizada no expone el parámetro de máximo de tokens. El control de longitud se aplica, entonces, en los dos puntos donde el sistema sí tiene control determinista: el truncado de la entrada y la instrucción de longitud sobre la salida.

Ahorro estimado frente a la alternativa no optimizada —modelo premium, sin truncado ni nodo Limit—: de unos 60 dólares mensuales a cero en el plan gratuito, o a menos de un dólar con un modelo económico de pago.

4. Seguridad y resiliencia

4.1 Minimización de datos

Medida	Implementación
Datos ficticios	La totalidad del conjunto de datos fue generado para este trabajo. Ninguna consulta real ingresa al sistema.
Casilla dedicada	El Gmail Trigger filtra por remitente. El correo personal del titular de la casilla no se procesa.
Descarte de metadatos	El nodo Set conserva únicamente el asunto, el remitente y el cuerpo. Los encabezados SMTP, las firmas DKIM y ARC y la versión HTML se descartan antes de cualquier llamada externa.
Superficie mínima ante el proveedor de IA	El modelo recibe tres campos de texto. No accede a la casilla, ni al historial, ni a los destinatarios en copia.
Truncado	El cuerpo se limita a 4.000 caracteres antes de salir del entorno.
Credenciales	Gestionadas por el almacén de credenciales de n8n. No aparecen en el JSON exportado ni en las expresiones.

4.2 Rutas de error

La estrategia tiene tres capas, ordenadas desde la falla más frecuente hasta la más grave.

Capa	Mecanismo	Qué cubre
1. Reintento automático	Reintento ante fallo (tres intentos) en los nodos con salida de red y en el modelo.	Tiempos de espera agotados, límites de tasa (429), cortes momentáneos
2. Salida de error dedicada	Continuar por la salida de error en los nodos de IA y de escritura. Ambas convergen en «Registra error en Notion».	Fallas de la API de IA, rechazos de escritura
3. Idempotencia	Campo «Respuesta enviada», evaluado en el filtro de la rama 2.	Envío duplicado ante un fallo parcial de la rama 2

Comportamiento ante un fallo: el flujo no se interrumpe en silencio. Se crea una fila en Consultas con el Estado y el Resultado en «Error», el mensaje del nodo que falló en «Detalle error», y el asunto y el remitente originales para permitir el reproceso. Los campos que la IA no llegó a completar quedan vacíos, lo que indica hasta qué punto avanzó el procesamiento.

Los registros de error se escriben en la misma tabla que las consultas exitosas, de modo deliberado: la tasa de errores del dashboard se calcula como la proporción de filas con Resultado igual a «Error» sobre el total. Si los errores residieran en una tabla separada, ese indicador no podría construirse con los gráficos nativos de Notion.

4.3 Prevención de bucles infinitos

El riesgo es estructural: la rama 2 escribe en la misma base que dispara su propio disparador. Se resuelve con una condición doble en el nodo «Filtra aprobadas sin responder»:

```
Estado == "Aprobado por Humano" AND Respuesta enviada == false
```

Secuencia real: el operador aprueba, el disparador se activa, el filtro se cumple, se envía el correo, se escribe «Finalizado» y se marca la respuesta como enviada. Esas escrituras vuelven a activar el disparador una vez más, el filtro ya no se cumple y el ciclo termina. Se produce una ejecución adicional, no un bucle.

Tipos de dato en el filtro: la primera condición compara cadenas de texto; la segunda, un valor booleano. n8n opera con validación estricta de tipos, de modo que comparar la casilla de verificación contra la cadena «false» genera un error de ejecución. Ambas condiciones están declaradas con el tipo que corresponde.

La base de conocimiento no interviene en este análisis, porque el flujo únicamente la lee.

4.4 Puntos de validación humana

Punto	Mecanismo
Antes de la acción crítica	Ningún correo se envía al remitente sin que una persona modifique el estado a «Aprobado por Humano». No existe ninguna ruta automática hacia el envío.
Notificación	Mensaje de Slack con semáforo de tres estados, resumen de la clasificación y enlace directo a la página de Notion.
Mecanismo de aprobación	Cambio manual del campo Estado en Notion. Ese cambio es lo que dispara la rama 2.
Derivación determinada por datos	El campo «Requiere revisión humana» de la base de conocimiento fuerza la derivación con independencia de lo que decida el modelo.
Sesgo hacia la derivación	Regla explícita en el prompt: ante cualquier duda, el tipo de resolución es «Requiere humano».
Vinculación de la ficha	La propiedad de relación se completa manualmente durante la revisión, lo que agrega un control adicional sobre la fuente citada.

Fundamento del sesgo hacia la derivación: el costo de derivar de más es que un agente lea un correo. El costo de responder de menos es que la Secretaría emita información incorrecta con carácter oficial. Los dos errores no son simétricos y el sistema está calibrado en consecuencia.

4.5 Los tres caminos de resolución

Tipo de resolución	Condición	Borrador generado
Responde IA	Existe una ficha aplicable y no está marcada para revisión	Respuesta completa que cita la ficha y la normativa
Requiere humano	No hay ficha aplicable, o la ficha está marcada, o se solicita una excepción, o se menciona un expediente en curso	Acuse de recibo sin contenido normativo
Solicita aclaración	La consulta no aporta información suficiente para identificar el tema	Pedido cordial de precisión sobre el tema consultado

En los tres casos el borrador queda sujeto a aprobación humana. La distinción no define si se revisa, sino qué tipo de intervención se requiere.

4.6 Limitaciones conocidas

- El Notion Trigger procesa una página por ciclo de sondeo. Un lote grande de aprobaciones simultáneas se drena a razón de una por minuto. Para un volumen mayor correspondería un disparador programado con lectura por lote filtrada por estado.
- El fallo en el envío del correo no genera un registro en Notion. La fila permanece en «Aprobado por Humano» con la respuesta sin marcar como enviada, por lo que no se pierde, pero el intento fallido no queda contabilizado.
- El truncado a 4.000 caracteres implica que una consulta muy extensa llegue incompleta al modelo. Se mitiga con la revisión humana obligatoria previa al envío.
- El agrupamiento de hilos de correo se resuelve mediante el prefijo «Re:» en el asunto, que es el criterio que utiliza Gmail, en lugar de un mapeo explícito del identificador de hilo.